Тестовые сценарии и ограничения

Прогулки по Астане — RAG-помощник, который подбирает 1–3 места рядом с пользователем. Build with AI 2026, секция AI for Smart City, кейс НИЦ Smart City.

Дата прогона	19 октября 2026, 18:45–18:54 по Астане (UTC+5), реальные серверные часы
Код продукта	коммит `70c553b` (ветка `main`); от него собран и запущен `pnpm build` + `pnpm start`
Данные	1250 мест в `data/poi.json`, собраны скриптом `pnpm collect` из OpenStreetMap и Wikidata 19.10.2026 (снимок OSM 13:20 UTC); фото Wikimedia Commons — у 15 мест
Поиск	эмбеддинги OpenAI `text-embedding-3-small`, 256 измерений, предрасчитаны для всех мест; без ключа и в режиме `mock` — лексический поиск
Модель агента	`gpt-6-luna` через OpenAI Responses API (режим `live`)
Сырые ответы	`docs/presentation-http-probes.json` — полный JSON каждого запроса и вызовов инструментов

Каждый сценарий отправлен настоящим HTTP-запросом в `POST /api/chat` дважды: сервер с `LLM_PROVIDER=mock` (без сети и ключа, инструменты вызываются по сценарию) и сервер с `LLM_PROVIDER=responses` (инструменты выбирает модель). Текст ответа в обоих режимах собирает код из результатов инструментов, поэтому модель не может дописать факты о месте.

Итог

#	Сценарий	Mock	Live	Ответ mock и live
1	Экспо 2017 — пример из кейса	пройден	пройден	совпадает
2	Mega Silk Way, прогулка 30–60 мин	пройден	пройден	совпадает
3	Тихое место с кофе и розеткой	пройден	пройден	2 из 3 мест те же
4	С ребёнком: площадки или музей	пройден	пройден	совпадает
5а	Турист, 2 часа до вылета, без локации	пройден	пройден	совпадает
5б	То же, с геолокацией	пройден	пройден	1 из 2 мест то же
6	Ночная активность	пройден	пройден	совпадает
7	Байтерек: маршрут из трёх мест на 90 мин	пройден	пройден*	2 из 3 остановок те же
8	На коляске: кафе до 10 минут	пройден	пройден	совпадает
9	Нур Алем: музей рядом — пустой результат	пройден	пройден	совпадает
10	Кофе в пределах 5 минут на окраине — пустой результат	пройден	пройден	совпадает
11	«Хочу погулять рядом со мной» без локации	пройден	пройден	совпадает

* В первом живом прогоне сценарий 7 был помечен «не пройден»: модель сразу вызвала `plan_walk` без отдельного `find_places`, а проверка требовала оба вызова. Маршрут при этом был верный (3 остановки, 89 мин). Проверка исправлена: для маршрута обязателен `plan_walk`; повторный прогон —

все 12 пройдены в обоих режимах.

Расхождения mock и live — только в выборе мест в сценариях 3, 5б и 7: в live работает семантический поиск по эмбеддингам, в mock — лексический. Формат, часы, источники и пометки одинаковы.

Время ответа live (второй прогон): медиана около 18 с, от 4 с (уточнение локации) до 53 с (Mega Silk Way). В первом прогоне — от 3 до 29 с, медиана около 16 с. Mock отвечает за 7–700 мс.

Критерии приёмки из кейса

Каждый ответ проверялся по требованиям организаторов (`docs/case.md`) и автоматически скриптом `pnpm scenarios`:

1. **1–3 конкретных места**, каждое с расстоянием и минутами пешком.
2. **Почему** — краткое объяснение для каждого места.
3. **Время на посещение** — сколько закладывать.
4. **Что делать там** — помечено «(сгенерированная идея)», потому что это не факт из данных.
5. **Источник** каждого места — ссылка на объект OpenStreetMap (и Wikidata, если описание оттуда).
6. **Честные часы**: «открыто» только если часы OSM это подтверждают на текущее время, иначе — «часы работы неизвестны — уточните перед выходом».
7. **Использованные данные названы**: локация и откуда она (браузер или слова пользователя), фильтры и категории.
8. Если локации нет — система **спрашивает**, а не угадывает.

Скрипт дополнительно проверяет: каждое выбранное место есть в результатах инструментов, его название и ссылка на источник есть в тексте, у каждого места ровно одна строка «Что делать» с пометкой, ночью рекомендуются только места с подтверждённым статусом «открыто», в режиме «на коляске» — только места с `wheelchair=yes`, маршрут укладывается в бюджет.

В разделах ниже ответы сокращены до строк о местах; полный текст — в JSON. Координаты в сценариях 3–6, 8 и 10 — тестовые, переданные в поле `location` так же, как их передаёт кнопка геолокации браузера (уже округлёнными).

---

1. Экспо 2017 — пример из кейса

Вход: «Я у здания Экспо 2017, хочу что-то необычное на 1–2 часа, пешком.» Локация — из текста.

Ожидаемый тип ответа: 1–3 необычных места рядом с Экспо с расстоянием, «почему», временем и планом; часы и источник у каждого.

Фактический ответ (mock и live — одинаковые места и текст):

```
Локация: Alem.ai (бывший Нур Алем), территория ЭКСПО (из ваших слов).
Фильтры: До 30 мин пешком до каждого места; Вся прогулка — до 120 мин; Категории:
достопримечательность, арт-объект, памятник, музей, …
Поблизости в данных мало музеев, галерей и арт-объектов, поэтому в списке есть места просто для
прогулки.

1. 25-ти летие Независимости — 507 м, 9 мин пешком (оценка).
Почему: достопримечательность — совпадает с запросом «необычное», 9 мин пешком.
На посещение: 30 мин (оценка).
Что делать: осмотреть достопримечательность и сделать короткую остановку (сгенерированная идея).
Часы: часы работы неизвестны — уточните перед выходом.
Источник места: OpenStreetMap (way/1460763574).

2. Аллея мира и согласия — 539 м, 10 мин пешком (оценка). Почему: парк рядом — для прогулки, не
достопримечательность.
3. NU Park — 1173 м, 21 мин пешком (оценка). Почему: парк рядом — для прогулки, не
достопримечательность.
```

Соответствие: 3 места — да; расстояние и минуты — да; почему — да; время — да; что делать с пометкой — да; источник — да; честные часы — да (у всех трёх «неизвестны»); локация и фильтры названы — да.

Замечания: сам «Нур Алем» исключён как точка старта. Музея будущего искусства и террасы отеля из примера организаторов в данных OSM нет, поэтому два места из трёх — парки, и ответ честно об этом предупреждает. «Почему» у памятника короткое: описания в данных нет.

2. Mega Silk Way, прогулка 30–60 минут

Вход: «Я сейчас возле Mega Silk Way, хочу прогуляться 30–60 минут — что посоветуете?» Локация — из текста.

Ожидаемый тип ответа: 1–3 места для короткой прогулки, укладывающиеся в 60 минут.

Фактический ответ (mock и live одинаковы; live вызвал поиск дважды):

```
Локация: Mega Silk Way (из ваших слов).
Фильтры: До 15 мин пешком до каждого места; Вся прогулка — до 60 мин; Категории: памятник, …, парк,
сад, кафе.

1. Лепим и варим — 62 м, 2 мин пешком (оценка).
Почему: кафе — остановка на кофе, открыто до 23:00, 2 мин пешком.
На посещение: 30 мин (оценка).
Что делать: выпить кофе и отдохнуть перед следующей остановкой (сгенерированная идея).
Часы: открыто до 23:00 по данным OpenStreetMap.

2. NU Park — 562 м, 10 мин пешком (оценка).
Почему: парк — подходит для прогулки, 10 мин пешком.
Часы: часы работы неизвестны — уточните перед выходом.
```

Соответствие: 2 места — да; все пункты чек-листа — да. Часы у кафе взяты из OSM и проверены на 18:45.

Замечания: в прогулку без явного интереса допускается не больше одного кафе. Самый медленный живой ответ прогона — 53 с.

3. Тихое место с кофе и розеткой

Вход: «Хочу тихое место с кофе и розеткой недалеко от меня.» Локация — браузер, 51.089, 71.416 (район ЭКСПО).

Ожидаемый тип ответа: 1–3 кафе рядом; честно — что про розетки и тишину известно.

Фактический ответ (live):

```
Локация: 51.089, 71.416 (геолокация браузера).
Фильтры: До 15 мин пешком до каждого места; Категории: кафе, библиотека.

1. Лепим и варим — 570 м, 10 мин пешком (оценка).
Почему: кафе — совпадает с запросом «кофе, розетка», открыто до 23:00, 10 мин пешком.
На посещение: 30 мин (оценка).
Розетки: данных нет — уточните перед выходом.
Уровень шума не проверен — уточните у места.
Что делать: выпить кофе и отдохнуть перед следующей остановкой (сгенерированная идея).
Часы: открыто до 23:00 по данным OpenStreetMap.

2. Gasteria — 465 м, 9 мин пешком (оценка). Открыто до 23:00.
3. Drinkit — 692 м, 12 мин пешком (оценка). Открыто до 22:00.
```

В mock: Gasteria (465 м), Starbucks (495 м, с описанием сети из Wikidata), Лепим и варим (570 м).

Соответствие: все пункты — да. Система не выдумывает розетки и тишину: в OSM таких данных нет, и это сказано у каждого места.

Замечания: в live первым стоит более дальнее место (570 м раньше 465 м) — порядок по релевантности, в ответе это не пояснено.

4. С ребёнком: детские площадки или музей с интерактивами

Вход: «Еду с ребёнком — где рядом есть детские площадки или музей с интерактивами?» Локация — браузер, 51.089, 71.416.

Ожидаемый тип ответа: площадки и/или музей рядом, с пометкой, что подходит детям.

Фактический ответ (mock и live одинаковы):

```
Фильтры: До 15 мин пешком до каждого места; Категории: детская площадка, музей, зоопарк.

1. Детская площадка, улица Акмешит — 261 м, 5 мин пешком (оценка).
Почему: детская площадка — совпадает с запросом «с ребёнком, интерактивы», по данным OSM подходит
детям.
На посещение: 40 мин (оценка).
Интерактивы: данных нет — уточните перед выходом.
Что делать: сделать остановку для игры с ребёнком, проверив состояние площадки на месте
(сгенерированная идея).

2. Alem.ai Международный центр искусственного интеллекта — 31 м, 1 мин пешком (оценка). Музей;
интерактивы: данных нет.
3. Детская площадка — 253 м, 5 мин пешком (оценка).
```

Соответствие: все пункты — да.

Замечания: у безымянных площадок название построено по ближайшей улице OSM; у третьей площадки улица не подставлена, и название осталось общим — две площадки трудно различить по тексту.

5а. Турист, 2 часа до вылета, без локации

Вход: «Я — турист, у меня 2 часа перед вылетом: что можно посмотреть поблизости?» Локации нет.

Ожидаемый тип ответа: уточнение — где пользователь и сколько времени реально свободно.

Фактический ответ (mock и live одинаковы, инструменты не вызывались):

> Где вы сейчас находитесь? Назовите ориентир или передайте геолокацию. Уточните также, сколько времени осталось с учётом дороги в аэропорт, регистрации и досмотра.

Соответствие: система не угадывает локацию — да.

5б. Турист, 2 часа до вылета, с геолокацией

Вход: тот же текст; локация — браузер, 51.128, 71.43 (у Байтерека).

Фактический ответ (live):

> Время дороги в аэропорт, регистрации и досмотра неизвестно — проверьте его и вычтите из времени до вылета. Весь запас нельзя отдавать прогулке.
>
> 1. Байтерек — 45 м, 1 мин пешком (оценка).
> Почему: памятник — совпадает с запросом «достопримечательности», заметное место по данным Wikidata/OSM.
> На посещение: 15 мин (оценка).
> Достопримечательность города (Wikidata).
> Что делать: осмотреть памятник и сделать фото (сгенерированная идея).
>
> 2. Астана-Экспо КС — 837 м, 15 мин пешком (оценка). Галерея; часы неизвестны.

В mock второе место — галерея «Корме» (675 м).

Соответствие: все пункты — да; дорога в аэропорт не выдумана.

Замечания: «Астана-Экспо КС» отмечена в OSM как галерея без описания и часов; по названию это может быть организация, а не выставочный зал. Пример сомнительной категории в исходных данных.

6. Ночная активность

Вход: «Ищу необычную ночную активность (последние пару часов).» Локация — браузер, 51.128, 71.43.

Ожидаемый тип ответа: 1–3 места, которые по данным открыты; места с неизвестными часами — не предлагать как ночные.

Фактический ответ (mock и live одинаковы):

```
Сейчас 18:53 по Астане — часы проверены на это время; ночью статус может отличаться.
У части найденных мест часы работы неизвестны — уточните перед выходом; они исключены из ночных рекомендаций.

1. Лигалайф — 333 м, 6 мин пешком (оценка). Бар; часы: открыто до 06:00 по данным OpenStreetMap.
2. Avtor — 456 м, 8 мин пешком (оценка). Бар; часы: открыто сейчас по данным OpenStreetMap (в OSM — 24/7).
3. Golpas — 509 м, 9 мин пешком (оценка). Бар; часы: открыто до 01:00 по данным OpenStreetMap.
```

Соответствие: все пункты — да; все три места имеют статус «открыто» по часам OSM.

Замечания: прогон был вечером, а не ночью; ответ сам говорит, на какое время проверены часы. Все три места — бары: других открытых ночью категорий рядом в данных нет.

7. Байтерек: маршрут из трёх мест на 90 минут

Вход: «Я у Байтерека, составь маршрут из трёх мест на 90 минут.» Локация — из текста.

Ожидаемый тип ответа: мини-маршрут ровно из 3 остановок, со временем переходов и посещений, не дольше 90 минут; путь — по пешеходной сети.

Фактический ответ (live):

```
Локация: Байтерек (из ваших слов).
Фильтры: Вся прогулка — до 90 мин, включая переходы и посещения; один переход — до 23 мин пешком;
Мест в маршруте: 3; Часы проверены на 18:53 по Астане.
Пеший маршрут: всего 87 мин, включая переходы и посещения (оценка).

1. Сквер — прибытие через 9 мин от старта. Переход: 624 м, 9 мин. На посещение: 25 мин.
2. Корме — прибытие через 39 мин от старта. Переход: 338 м, 5 мин. На посещение: 20 мин.
3. Астана-Экспо КС — прибытие через 67 мин от старта. Переход: 597 м, 8 мин. На посещение: 20 мин.

Чтобы уместить все остановки, время на части посещений сокращено (оценка). Путь по пешеходным дорожкам OpenStreetMap; входы, лестницы и временные перекрытия не проверены.
```

В mock третья остановка — «Табун Лошадей» (726 м, 10 мин), всего 89 мин.

Соответствие: 3 остановки — да; бюджет 90 мин соблюдён — да (87 и 89 мин); у каждой остановки почему, что делать с пометкой, источник и часы — да.

Замечания: «Сквер» — родовое название из OSM без описания; полезность такой остановки пользователь не может оценить заранее.

8. На коляске: кафе до 10 минут

Вход: «Передвигаюсь на коляске, найди кафе в пределах 10 минут пешком.» Локация — браузер, 51.128, 71.43.

Ожидаемый тип ответа: только места с подтверждённой доступностью; если таких нет — честно сказать.

Фактический ответ (mock и live одинаковы):

```
Фильтры: До 10 мин пешком до каждого места; Категории: кафе, библиотека; Только места с подтверждённой доступностью для колясок.
Подходящих мест с этими условиями не найдено. Попробуйте изменить фильтры.
```

Соответствие: фильтр назван — да; место без подтверждения не выдано за доступное — да.

Замечания: `wheelchair=yes` есть только у 42 из 1250 мест. Маршрутизация для коляски не поддерживается: в пешеходной сети разрешены ступени.

9. Нур Алем: музей рядом — пустой результат

Вход: «Я у Нур Алем, хочу посмотреть музей или необычное место на 1–2 часа пешком.»

Фактический ответ (mock и live одинаковы):

```
Локация: Alem.ai (бывший Нур Алем), территория ЭКСПО (из ваших слов).
Фильтры: До 30 мин пешком до каждого места; Вся прогулка — до 120 мин; Категории: музей, галерея.
Подходящих мест с этими условиями не найдено. Попробуйте изменить фильтры.
```

Соответствие: честный пустой ответ — да.

Замечания: «музей» в запросе превращается в фильтр «музей, галерея», а сам Нур Алем исключён как точка старта. Ответ мог бы предложить расширить фильтр до достопримечательностей (как в сценарии 1) — сейчас он только советует изменить фильтры.

10. Кофе в пределах 5 минут на окраине — пустой результат

Вход: «Хочу кофе в пределах 5 минут пешком.» Локация — браузер, 51.04, 71.27 (юго-западный край области данных).

Фактический ответ: «Подходящих мест с этими условиями не найдено. Попробуйте изменить фильтры.» Фильтры «до 5 мин пешком; кафе, библиотека» названы.

Соответствие: система не подставляет далёкие места, чтобы ответ не был пустым — да.

11. Без локации

Вход: «Хочу погулять рядом со мной.» Локации нет.

Фактический ответ: «Где вы сейчас находитесь? Назовите ориентир или передайте геолокацию.»

Соответствие: спрашивает, а не угадывает — да.

Сомнительные и неполные данные

Ситуация	Что делает система
Часов работы нет (у 927 из 1250 мест)	«часы работы неизвестны — уточните перед выходом»; ночью такие места не рекомендуются
Часы разобраны частично	статус с пометкой «уверенность низкая — уточните перед выходом»

Ситуация	Что делает система
Место закрыто по часам OSM	«сейчас закрыто по данным OpenStreetMap, откроется в …»; закрытые места в выдаче последние, маршрут их не берёт
Нет данных о розетках, тишине, интерактивах	так и сказано у каждого места («данных нет — уточните»)
Безымянные площадки	283 названия построены шаблоном «Детская/Смотровая площадка, <улица OSM в пределах 150 м>»; без улицы — общее название
Ошибочные связи OSM→Wikidata	связь принимается, только если названия совпадают по слову от 4 букв; 4 связи отклонены и записаны в `data/collect_raw.json`
Описание сети, а не филиала	помечено «Сеть …» (28 мест)
Мероприятия, выставки, афиша	данных нет — система их не обещает; «что делать» — помеченная сгенерированная идея
Ничего не найдено	честный пустой ответ с названными фильтрами (сценарии 8–10)
Семантический поиск недоступен	откат на лексический поиск, ответ сообщает об этом строкой «Использован лексический поиск без эмбеддингов»

Гостиницы и посуточная аренда исключены при сборе (131 объект), дубликаты удалены (62). Связь с Wikidata есть у 23 мест, описания — у 47, фото с проверенной свободной лицензией — у 15.

Этика и приватность

- **Геолокация — только по кнопке** «Использовать мою геолокацию». Без нажатия браузер координаты не передаёт; можно просто написать ориентир.
- **Округление до ~100 м** (3 знака после запятой) — дважды: в браузере и на сервере при проверке запроса, до того как координаты увидит модель.
- **Ничего не хранится**: нет базы данных, аккаунтов и истории. Координаты и тексты запросов не кэшируются и не логируются; в лог API пишется только категория ошибки.
- **Провайдер модели видит текст запроса** в режиме live (OpenAI Responses и эмбеддинги). В режиме mock данные не покидают сервер. Пеший маршрут считается локально, координаты маршрутизатору не отправляются.
- **Источники помечены**: у каждого места — ссылка на объект OpenStreetMap; описания из Wikidata подписаны «(Wikidata)».
- **Сгенерированное помечено**: каждая строка «Что делать» заканчивается «(сгенерированная идея)»; расстояния, время и длительность посещения — «(оценка)».
- **Нет уверенного «открыто»** без данных: статус «открыто» только по часам OSM на текущее время.
- **Лицензии**: © участники OpenStreetMap (ODbL), Wikidata (CC0), фото Wikimedia Commons с автором и лицензией у каждого изображения. Сервисы, запрещающие парсинг (Google Maps, 2GIS, Яндекс), не используются для сбора данных.

Ограничения

- **Свежесть OSM**: снимок 19.10.2026. Закрывшиеся и новые места, сменившиеся часы не отражаются до повторного `pnpm collect`.

- **Покрытие**: часы работы — 25,8 % мест, описания — 3,8 %, Wikidata — 1,8 %, фото — 1,2 %, доступность для колясок — 42 места. Это выборка в прямоугольнике Астаны, не полный реестр.
- **Расстояния в поиске — оценка**: прямая с поправкой на улицы. Точный путь считается только в маршруте.
- **Пешеходная сеть** (134 017 узлов, 309 938 рёбер, 862 несвязанных компонента): входы в здания, лестницы и временные перекрытия не проверены; ступени допускаются, поэтому маршрут не годится для коляски. Если точки не соединены, линия не рисуется и это сообщается.
- **Нет данных** о погоде, событиях, ценах, загруженности, дороге до аэропорта.
- **Сомнительные категории OSM** попадают в ответ как есть (пример — «Астана-Экспо КС» как галерея).
- **Модель может ошибиться в выборе инструмента**; формат ответа и проверки фактов от этого защищены, потому что текст собирает код. В прогоне модель 1 раз пропустила необязательный поиск перед маршрутом.
- **Задержка live**: в этом прогоне медиана 16–18 с, максимум 53 с. Эмбеддинг запроса имеет таймаут 8 с; в первом живом прогоне поиск в нескольких сценариях откатился на лексический (об этом сказано в ответе), во втором — ни разу. Причина не установлена.
- **Один город и один язык ответа** — русский.

Как воспроизвести

```
pnpm install
pnpm build
# mock: без ключа и сети
LLM_PROVIDER=mock pnpm start -p 3201
pnpm scenarios http://127.0.0.1:3201 mock
# live: нужен LLM_API_KEY в .env
LLM_PROVIDER=responses pnpm start -p 3202
pnpm scenarios http://127.0.0.1:3202 live
# PDF этого документа (нужен установленный Chrome)
pnpm scenarios:pdf
```

PowerShell: `$env:LLM_PROVIDER='mock'; pnpm start -p 3201`. Скрипт `pnpm scenarios` записывает результат прогона в `docs/presentation-http-probes.json` (раздел `runs.mock` или `runs.live`) и завершается с ошибкой, если хоть один сценарий нарушил проверки. Результаты зависят от текущего времени: статус часов вычисляется на момент запроса по Астане.

Пересборка данных: `pnpm collect` (места), `pnpm embed` (векторы, нужен ключ).